

Ch_16 Evaluations - 서기

4개의 챕터만 선정

- RAG 시스템 구현했을 때, "이 시스템이 실제로 잘 동작하고 있는가?"
- 이 질문을 하나의 흐름으로 잘 연결하고 있음

합성 테스트 데이터셋 생성(RAGAS)

왜 합성 데이터인가?

- 사람이 질문을 직접 만들면 너무 오래걸리고, 복잡한 추론 수준에 도달하기 어려움

[한계]

- LLM이 문서 기반으로 질문을 만들다 보니, 문서에 없는 이상한 질문 같은 경우에는 합성 데이터가 커버할 수 없음.

RAGAS 정량 평가

- 검색 완전성
- 검색 정밀도
- 답변 관련성
- 답변 충실도

⇒ 4개 지표를 함께 보면 파이프라인이 어느 부분이 문제가 있는지 구체적으로 진단 가능

ex) faithfulness가 낮으면 컨텍스트 밖 내용을 질문하지 않았는지 다시 생각 가능

LangSmith LLM-as-Judge

평가자 유형

QA: 질문과 답변만으로 정오 판단

Context QA: 정답 대신 컨텍스트 참조

COT QA: 추론 과정을 거쳐 판단

Criteria: 정답 없이 기준으로 평가

Labeled Score: 1~10점 척도로 점수 반환

⇒ 문법이 맞는가, 답변이 적절한가와 같은 주관적인 질문들을 측정을 잘 못함

→ 사람이 직접 판단하거나 LLM이 하도록 평가하도록 해야함!

- LLM이 LLM을 평가하는 거다 보니, 성능이 좋아야 함.
- GPT 버전이 똑같은 걸 사용하다 보면, 오답을 정답으로 판단하는 경우가 발생할 수 있음

LangSmith Online Evaluation

: 앞은 오프라인 평가, 이걸 실시간 품질 모니터링

- 개발자가 예상하지 못한 질문을 한다고 했을 때, 실제 트래픽에서 품질이 떨어지는 경우가 굉장히 많다 → 온라인 평가가 중요해짐!
- LangSmith에 로깅된 실행 결과에 대해 ⇒ 비용이 커지는 걸 막기 위해 Tag 기반 선택적 평가를 실시
- 모니터링할 지표를 미리 선정해야함!
 - 안 그러면 온라인 평가가 의미없어짐.

합성 데이터로 만든 데이터셋 → 사용자 질문을 완전히 대체하진 못함

LLM 평가는 비용이 높음 → 온라인 평가만으로는 서비스 품질을 판단할 수 없음!

⇒ 4가지 RAG 평가로 하나의 사이클을 만든 것이다~

Q&A

Q. 사용한 모델보다 더 성능이 좋은 모델로 평가해야한다고 했는데, 더 좋다는 기준이 있는가?

A. 정확한 기준까진 모르겠지만, 상위 버전으로 사용하는 것이 좋다고 한다. 보통 실무에서는 벤치마크 점수라는 기준이 있는데, 점수 기준에서 더 높은 점수를 받은 모델을 평가자로 선정한다고 한다. 구체적인 건 잘 모르지만 상위 버전을 사용하면 좋다!